

Token 经济学 与消耗管控

OpenClaw 精准打击策略实战 · 从压缩、调度到熔断的三层防线

PROMPT 压缩

结构化提取 减少冗余

按需调用

多 Endpoint Token 节食

监控熔断

阈值告警 自动回滚

本次议程

从背景到落地，四个章节看懂 Token 成本治理

01

背景与挑战

Token 消耗失控的真实场景与成本结构



02

三大精准打击策略

Prompt 压缩 · 按需调用 · 监控熔断



03

OpenClaw 工程实践

代码层 Token 计数器与多 Endpoint 调度



04

效果复盘与行动清单

ROI 数据与团队落地的 5 个关键步骤



为什么 Token 是新的 "水电煤" ?

大模型时代，每一次推理调用都是一次精确计费

73%

AI 项目成本

Token 调用费用占 AI 应用总成本比例

5x

调用量增长

过去 12 个月企业 LLM API 调用量翻番速度

42%

可优化冗余

典型 Prompt 中无效或重复上下文占比

数据来源: OpenClaw 内部基线测量 + 行业平均 (n=120 项目)

失控的三种典型场景

财务季度对账时，最常见的三类 Token 账单刺客



PROMPT BLOAT

上下文膨胀

用户每次提问都把整段教育背景、PDF 全文塞进 Prompt，单次请求轻易突破 8K Token。



OVER-MODEL

模型错配

简单 if-else 判定也调用 GPT-4 级模型，单价是同等效果小模型的 30 倍以上。



RUNAWAY LOOP

失败重试

异常分支无限重试，没有熔断机制，一次 Bug 半小时烧掉单日预算。

一笔 Token 账单是怎么算出来的

拆解一次智能体调用，看每一分钱花在哪里

典型调用成本构成



INSIGHT

\$ 0.47

单次智能体任务平均成本

其中约 70% 是可压缩的输入上下文与无效重试 — 即 OpenClaw 三大策略的攻击面。

OpenClaw 的精准打击思想

不做粗暴限流，而是在每一层都建立可观测、可干预、可回滚的护栏

“

*Token 不是限制，而是预算。把每一次调用都当成一次有意识的支出，
而不是默认的自由操作。*

– OpenClaw Engineering Principles

01

可观测

每一笔 Token 必须可被计量与追踪

02

可干预

在调用前后都可注入策略与压缩逻辑

03

可回滚

单任务超额自动熔断，不污染下游

三大精准打击策略

从输入端、调度层到运行时，构建立体的 Token 防御体系

INPUT LAYER

STRATEGY 01

Prompt 压缩

Compression

用 Copilot 对冗长教育背景资料做结构化提取，减少上下文冗余。

DISPATCH LAYER

STRATEGY 02

按需调用

Routing

OpenClaw 配置不同 Model Endpoint，简单逻辑走小模型 "Token 节食"。

RUNTIME LAYER

STRATEGY 03

监控与熔断

Circuit-Break

代码层实现 Token 计数器，单次任务超阈值自动触发回滚。

策略一 · Prompt 压缩

Copilot 把冗长背景资料压成结构化片段，从源头切掉无效 Token

核心动作

- 识别冗余 — 教育经历、产品手册、合同模板等长尾文本
- 结构化抽取 — Copilot 转 JSON/字段，丢掉自然语言修饰
- 动态注入 — Prompt 只携带任务真正需要的字段
- 缓存复用 — 相同实体的结构化结果 24h 内复用

压缩漏斗



Copilot 结构化提取流程

5 个步骤把一份非结构化材料变成可被 Prompt 直接消费的字段



```
// Copilot extract schema
```

```
{ "name": str, "degree": str, "school": str, "major": str, "year": int, "achievements": str[3] }
```

→ 仅保留任务匹配所需 6 个字段，剔除 90% 自然语言修饰

→ Schema 化字段可被多任务复用，避免重复抽取

案例 · 教育背景资料压缩

招聘场景下，候选人简历从 2,800 → 180 tokens 的真实对比

BEFORE · 原始 Prompt

2,800 tokens

"张三于2018年9月就读于清华大学计算机科学与技术系，主修人工智能方向，期间获得国家奖学金，参与了ACM比赛并获得亚洲区铜牌.....（接2,500字背景叙述、社团经历、获奖详情、推荐信摘录）"

AFTER · Copilot 抽取后

180 tokens

```
{
  "name": "张三",
  "degree": "本科",
  "school": "清华大学",
  "major": "计算机·AI 方向",
  "year": 2022,
  "achievements": [
    "国家奖学金",
    "ACM 亚洲区铜牌"
  ]
}
```

策略一的真实效果

2 周内的 12 个生产工作流，统一替换为 Copilot 结构化注入

AVERAGE PROMPT REDUCTION

-78%

跨 12 个工作流的平均 Prompt 体积下降

最高单流降幅 96.6%

月度 Token 账单

↓ 64%

平均响应延迟

↓ 41%

可缓存命中率

↑ 3.2×

线上首响时间 (P95)

↓ 38%

策略二 · 按需调用

OpenClaw 内多 Endpoint 路由，让 "杀鸡的活别用宰牛刀"

为什么要 Token 节食

成本敏感

GPT-4 vs 7B 小模型单价相差 30x，简单分类无须高阶模型


延迟敏感

本地小模型 200ms 内响应，云端大模型平均 1.8 秒

可控性

结构化抽取、关键词匹配、规则判断完全可由小模型胜任

OpenClaw 路由示意



依据复杂度评分自动选路

Model Endpoint 配置矩阵


OpenClaw 中按任务复杂度划分四档 Endpoint，明码实价

任务类型	推荐 Endpoint	示例	单价 / 1K Token	预算占比
分类 / 路由判定	Tiny · 1.5B	意图识别、敏感词过滤	\$0.0004	5%
结构化抽取	Small · 7B	简历字段、合同条款	\$0.0010	20%
对话与摘要	Mid · 70B	客服对话、文档摘要	\$0.0120	45%
复杂推理	Large · GPT-4 级	多步代码生成、Agent 决策	\$0.0300	30%

规则：每个 Workflow 显式声明 endpoint_tag，未声明默认走 Tiny → 强制开发者主动选择档位。


Token 节食决策树

调用前的 30 毫秒判定，决定这次请求该 "吃多少卡路里"



Token 节食带来的成本曲线

同一个工作流：默认全大模型 vs OpenClaw 智能调度



MONTHLY SAVING

-66.6%

月度账单从 \$4,820 降至 \$1,610

- 62% 流量被路由到 Tiny / Small 档
- 仅 8% 复杂任务保留 GPT-4 级
- P95 延迟同时下降 41%

策略三 · 监控与熔断

代码层 Token 计数器 · 阈值告警 · 自动回滚

LIVE TOKEN METER

当前任务消耗

8,420 / 10,000



80% 阈值

状态 **WARN · 接近阈值**

动作 **降级到 Mid 档 + 中止后续推理**

回滚 **Checkpoint @step3 已就位**

熔断的三层动作

Throttle · 限速

60% 阈值后降低并发，逐步收紧

Downgrade · 降级

80% 阈值后强制路由到更小模型

Rollback · 回滚

100% 阈值后中止任务并回放快照

Token 计数器架构

代码层非侵入式接入：装饰器 + 中间件 + 旁路指标

INTERCEPTOR

请求拦截

@token_meter 装饰器
挂在每个 LLM 调用上



COUNTER CORE

计数核心

记账 → 阈值评估 → 触发动作
基于内存 + Redis 双写



ACTION HUB

动作总线

Throttle / Downgrade / Rollback
输出到日志 + Prometheus

```
@token_meter(budget=10_000, on_exceed="rollback")
```

```
def run_agent(task): ...
```

阈值触发与回滚时序

从计数到回滚，毫秒级响应防止单任务“烧穿”预算



熔断触发后：本次任务不计入用户结果，但完整事件链路写入 Trace，供事后回放调参。

三策叠加之后

试点 8 周，覆盖 23 个生产工作流的合成数据

MONTHLY TOKEN SPEND

\$ 187K → \$ 41K

-78%

8 周内完成迁移，团队 0 加班、0 线上故障

-78%

月度 Token 账单

-41%

P95 响应延迟

+3.2x

缓存命中率

0

因超额导致的故障

把策略变成 下周一就能开工的 5 件事

- 1 为每个 Workflow 标注 endpoint_tag, 默认值收紧到 Tiny
- 2 把最长的 3 份背景资料用 Copilot 抽成 JSON Schema
- 3 在 LLM 客户端套上 @token_meter 装饰器与 budget
- 4 Prometheus 接入 token_used / threshold / rollback 三指标
- 5 每周成本评审：按 Workflow 看 P95 Token 与单价