

工程白皮书 • V1.0

Skill 定义 与测试标准

Coding Agent 的原子能力 ——
以及保证其稳定可靠的测试方法。

讲述人

Kinfey Lo

Microsoft Senior Cloud Advocate

日期

2026 年 5 月

受众

Agent 构建者
QA 与开发工具工程师

CONTENTS

本场要讲的内容

01 Skill 的定义

在 Coding Agent 语境下，什么是 Skill。

03 为什么要测试

Skill 为何必须配独立的测试闭环。

05 边缘测试集构建

教育视频场景的 10 个边缘知识点。

02 结构与设计原则

原子函数、契约、可测试性。

04 测试 Agent 模式

用对抗 Agent 攻击业务 Agent 的边界。

06 格式一致性校验

跨次运行的脚本格式与结构稳定性。

01

PART ONE

什么是 Skill?

在 Coding Agent 范式中, Skill 是能力的最小单元 —— 命名清晰、职责单一、可独立验证。

DEFINITION

Skill 是什么?

定义

Skill 是 Agent 可调用的原子化函数 —— 完成一件定义清晰的事情，输入与输出均有契约。

职责单一 · 命名规范 · 版本化 · 可独立测试

```
skill.spec

name: generate_ffmpeg_script
input: { source, target_format, bitrate }
output: shell_script (deterministic)
side_effects: none
version: 1.2.0
```

DISTINCTION

Skill、Tool、Agent 三者关系

TOOL

底层能力

最底层的绑定，例如 HTTP 调用、Shell 执行、文件读取。无状态，不知意图。

SKILL

原子函数

一个具名、契约清晰的动作；组合若干 Tool 完成一个明确的意图。

AGENT

调度者

做决策、规划、循环重试，决定何时调用哪个 Skill。

Skill 处在 Tool 与 Agent 之间 —— 是「最小但可独立测试」的能力单位。

ANATOMY

一个 Skill 由什么组成

01 契约

类型化输入、类型化输出、副作用声明。

02 实现

纯函数或工具组合，不含调度逻辑。

03 前置条件

调用前必须为真的状态。

04 后置条件

成功执行后调用方可依赖的结果。

05 失败模式

明确的错误分类：可恢复 vs 致命。

06 测试集

与 Skill 同源同版本，是发布门禁。

PRINCIPLES

Skill 的五条设计原则

ATOMIC

原子化

只做一件事。如果描述里出现「并且」，就拆开。

DETERMINISTIC

确定性

相同输入产出相同输出；随机性必须显式化为参数。

DECLARATIVE

声明式

输入输出皆类型化，契约即真相。

BOUNDED

可度量

延迟、成本、副作用都落在文档化的边界内。

OBSERVABLE

可观测

结构化输出轨迹：输入、决策、输出、失败原因。

REFERENCE SKILL

范例：generate_ffmpeg_script

函数签名

Input

```
source_path: str
target_format: enum
bitrate_kbps: int?
resolution: 'hd' | 'sd'?
```

Output

```
shell_script: str
est_runtime_sec: int
```

契约约束

- 纯函数 —— 不写文件系统。
- 输出为单行 ffmpeg 命令字符串。
- 不使用管道；命令始终单行可重放。
- 对路径加引号，处理空格与中文。
- 不支持的目标格式抛出 InvalidFormat。
- 码率低于 64 kbps 抛出 BitrateOutOfRange。

CATALOG

更多 Skill，相同的形态

媒体

`generate_ffmpeg_script`

→ shell 脚本

文档

`extract_pdf_tables`

→ json 数组

数据

`build_sql_query`

→ sql 字符串

可视化

`render_chart_spec`

→ vega-lite json

代码

`lint_python_snippet`

→ 诊断对象数组

文本

`summarise_transcript`

→ 结构化 markdown

02

PART TWO

自动化 Skill 测评

Skill 的可靠性取决于边界测试。我们需要的是「攻击者」，而不是「检查员」。

PROBLEM

Skill 测试为什么难

输入组合爆炸

自由参数维度叠加，单元测试只能覆盖人能想到的样本。

隐含假设漂移

LLM 驱动的 Skill 暗含提示词与模型版本的隐性约束。

格式悄悄走样

功能用例通过的同时，输出结构可能逐版本悄悄变形。

无人工兜底

Agent 自主调用 Skill，运行时没有人在回路里拦下错误。

PATTERN

测试 Agent 模式

编写一个对抗式的「测试 Agent」，专门用于攻击业务 Agent 的边界情况。

业务 Agent

- 持有被验证的 Skill。
- 把每个请求都当作生产流量来响应。
- 返回符合契约的类型化输出。

测试 Agent（攻击者）

- 依据策略库构造探测性输入。
- 对照契约与格式校验输出。
- 记录每次失败及可复现的种子。

LOOP

测试 Agent 的工作闭环



ATTACK LIBRARY

测试 Agent 的攻击策略

BOUNDARY

边界值

极小、极大、空、超长、Unicode 边缘字符。

MUTATION

输入变异

字段交换、丢失、重复，模糊化打散参数。

ADVERSARY

对抗提示

诱导 Skill 偏离契约的恶意意图输入。

REPLAY

确定性重放

同一输入连跑 N 次，输出必须逐字节一致。

CROSS

跨语言/编码

非 ASCII 文件名、RTL 文本、奇怪编码。

STRESS

压力包络

超长输入、深层嵌套、时间与成本探测。

METHOD

如何建立 Skill 测试集

测试集原则

- 精挑而非随机 —— 每条用例都验证一个假设。
- 短小、快速、可重复。
- 格式校验依赖冻结的 golden 输出。
- 与 Skill 同源同版本管理。
- 发布门禁：必须 100% 通过。

推荐用例配比



CASE STUDY

案例：教育视频脚本 Skill

场景说明

将一个知识点转换为 60 秒教育视频脚本的 Skill。

输出必须遵循固定结构：钩子 → 讲解 → 例子 → 总结，每段都带时间戳。

OUTPUT SCHEMA

```
{
  topic: string,
  duration_sec: 60,
  sections: [
    { name: hook,      t: 0,   text },
    { name: explanation, t: 8,   text },
    { name: example,    t: 30,  text },
    { name: recap,      t: 50,  text }
  ]
}
```


EDGE SET

预设 10 个边缘知识点

#	类型	示例	测试目的
01	单符号主题	圆周率 π	极短输入也要填满 schema
02	空知识点输入	(空白)	必须以 InvalidTopic 拒绝
03	歧义术语	集合 (数学/CS)	必须先消歧再生成
04	高度专业	黎曼 zeta 函数	保持适合普通受众的难度
05	跨学科	视觉的生物物理	段落间不允许标题
06	非拉丁文输入	中文「线性代数」	输出语言必须与输入一致
07	过时事实	冥王星是行星吗	需提示已更新的科学共识
08	敏感话题	AI 伦理权衡	需保持中立框架
09	数字密集	斐波那契 mod 素数	不允许编造数值
10	过程类知识	DNS 如何解析域名	严格保留步骤顺序

VALIDATION

输出格式一致性校验

相同输入 → 相同结构。跨多次运行、跨模型、跨提示词版本。

01

Schema 校验

JSON 严格符合冻结的 schema，不允许多键或缺键。

02

顺序校验

段落必须按契约顺序出现，不允许重排。

03

篇幅校验

每段文本以朗读速率落入声明的时间预算内。

04

差异校验

多次调用同一输入，结构化输出必须完全相同。

GATES

评分与发布门禁

100%

Schema 通过率

≥ 95%

边缘用例通过率

0

5 次回放结构差异

发布门禁流程

编写 Skill



运行测试 Agent



复盘失败用例



冻结 golden



发布上线

KEY TAKEAWAYS

做得小 · 测得狠

01 Skill 是原子

一个名字、一份契约、一件事；带「并且」就该拆。

02 契约即真相

输入、输出、副作用、失败模式都要显式声明。

03 用 Agent 测 Agent

对抗式 Agent 找到人类作者忽略的边界。

04 锁住格式

schema、golden、差异校验，三道门禁守住每次发布。