

Coding Agent 时代

OpenCode · **OpenClaw** · GitHub Copilot

三大平台的Token 经济观察与开发者实战指南

 议 程

今天我们聊什么？

01

Coding Agent 简介

为什么 2026 年开发流程被重塑

02

三大平台横向解构

OpenCode · OpenClaw · GitHub Copilot

03

Token 消耗特征

计费模型、放大器、可优化空间

04

选型与成本优化

场景匹配+ 实战建议

第一章

什么是 Coding Agent?

不再是「补全」, 而是「代理」.

Coding Agent 能够规划、调用工具、读取文件、运行 shell, 在多步骤循环中独立推进任务——直到目标达成或被人工干预。



目标驱动

理解高层意图, 自主分解任务



工具调用

读写文件、执行命令、检索代码



多轮循环

规划 → 行动 → 观察 → 反思

■ 全景图

三大平台 · 三种哲学



OpenCode

开放 · 终端优先

- sst 出品, 完全开源
- 模型无关 (BYOM)
- Build / Plan 双 Agent

成本 = 模型直通



OpenClaw / Pi

极简 · 自演进

- 仅 4 个内置工具
- Pi 通过自我改写扩展
- WhatsApp 端到端体验

成本 = 极小内核



GitHub Copilot

企业 · 一体化

- IDE Agent + Cloud Agent
- Premium Request 计费
- 向 Token 限额过渡中

成本 = 套餐 + 额度

第二章 / OpenCode

终端原生的开源 Coding Agent

由 *sst* 团队开源, **完全开放 · 模型无关**.

OpenCode 把 Coding Agent 当作一个独立的命令行工具, 直接嵌入开发者既有的终端工作流。它不绑定任何特定模型, 你可以在 Anthropic、OpenAI、本地 Ollama 等多家提供商之间灵活切换。

代码许可	MIT, 完全开源	运行界面	TUI / 终端
模型支持	多家 API + 本地	扩展形态	自定义 Agent / 工具

```
opencode

$ opencode
  > 选择模型: claude-sonnet-4.6
  > 模式: Build

user > 修复 utils 里的边界问题
  > 读取 utils.ts
  > 运行 npm test
  > 提交补丁
✓ 完成 · 3 个测试通过
```

 OpenCode / 架构

Build · Plan · 子代理协同

Build

PRIMARY · 全工具

默认开发主代理, 拥有读、写、执行、搜索全部权限。

Plan

PRIMARY · 受限

只读规划代理, 用于审查、设计、避免误操作。

调用 · 协作

**General**

SUBAGENT

通用研究 + 多步任务委派

**Explore**

SUBAGENT

只读探索, 适合大型代码库定位

OpenCode / Token

直通模型：透明、灵活、可优化

Token 流向

1

OpenCode CLI

仅做编排

2

提供商 API

Claude / GPT / Local

3

你的钱包

Token 计费按量

**完全透明**

无平台加价, 模型厂商定价直通

**可控杠杆**

选模型 / 缓存 / 子代理来摊薄成本

**数据自主**

可走自建网关, 配额、审计统一管理

注意: Agent 多轮循环易在大上下文中放大Token, 建议配合Plan模式与本地缓存。

第三章 / OpenClaw

极简之美: WhatsApp 上的 AI, 背后是 Pi



OpenClaw

WhatsApp · 个人 AI 助手

由 Peter Steinberger 推出, 圣诞期间爆红; 底层是 Mario Zechner 的极简 Coding Agent — Pi。

01 只 4 个工具

read · write · edit · bash, 内核精简到底

02 自我改写

需要新功能? 让 Pi 修改 Pi 自己, 非工程师也能扩展

03 AI 节制

拒绝把所有花哨能力推进单一二进制

 OpenClaw / 哲学

为什么「少即是多」？



AI 工具应该克制, 而不是不断膨胀。我们把最复杂的部分交给模型, 把最简单的部分交给用户。

— Mario Zechner, Pi 作者

传统 Agent

数十种内置工具, 学习曲线陡

新需求 = 等开发者发版本

复杂界面、复杂菜单

OpenClaw / Pi

4 个工具 · 5 分钟上手

新需求 = 让 Pi 改自己

WhatsApp 一条消息

OpenClaw / Token

极小内核 = 极小 Token 基线



4
个内置工具

更少的工具 schema 注入 prompt → 系统提示词 token 比同类平台显著更低

Token 特征

-  系统提示词极轻
工具描述少, 上下文窗口留给业务
-  **BYOM** 自己付账
Token 成本完全由用户的 LLM 账户承担
-  可审计、可重写
开源 + 自改写, 哪一段烧 Token 一目了然
-  复杂任务多轮
工具粒度小, 复杂任务可能多次循环

第四章 / GitHub Copilot

从代码补全, 走向多形态 Coding Agent

2021**代码补全**

Copilot 起步, 编辑器 ghost text

2024**Chat 与 Spaces**

对话式辅助, 多模型选择

2025**Agent Mode**

IDE 内多步代理 + Cloud Agent

2026**Token 时代**

限额从 Request 转向 Token

两种 Agent 形态并存

- IDE Agent Mode: 编辑器内交互式多步代理
- Copilot Cloud Agent: 在 GitHub Actions 上后台运行, 处理 Issue 与 PR

 Copilot / Agent 形态

IDE 内交互 vs Cloud 后台委派



Agent Mode (IDE)

INTERACTIVE

- 在 VS Code / Visual Studio / JetBrains 内运行
- 可读写文件、运行终端、调用 MCP 工具
- 每次用户发起的请求 = 1 Premium Request
- 适合实时迭代、视觉验证场景



Cloud Agent (远端)


DELEGATED

- 委派给 Issue / PR, 在 Actions 中后台执行
- 整个 Session = 1 Premium Request (固定)
- Session 期间消耗 GitHub Actions 分钟数
- 适合长任务、批量改、DRI 异步协作

Copilot / 计费

Premium Request 与模型放大器

模型放大器（示例）



套餐月度 Premium 额度

套餐	月度额度
Free	50
Pro	300
Pro+	1,500
Business	300 / 用户
Enterprise	1,000 / 用户

超额: \$0.04 / Premium Request — 50× 模型 1 次 = \$2.00

2026 年 6 月起 Copilot 将逐步切换为 Token 限额计量。

■ 横向对比

三种 Token 计费哲学

维度	OpenCode	OpenClaw / Pi	GitHub Copilot
计费模式	模型 API 直通	模型 API 直通 (BYOM)	Premium Request → Token
透明度	高 · 看得见每个 token	高 · 内核小, 易审计	中 · 倍数与限额需自查
平台抽成	无	无	有 (订阅 + 超额)
可优化点	选模型 / 缓存 / 子代理	重写 Pi 自身, 自定义工具	选模型, 控制 Agent 步数
典型成本结构	按 token 双线计 (输入+输出)	按 token 双线计, 基线低	套餐固定 + 超额 \$0.04
大上下文影响	明显, 直接体现在账单	明显, 但工具上下文小	通过 Token 限额体现

Token 消耗特征

把账单拆开看

OpenCode

高自由度 · 高责任

100%

Token 直接来自厂商账单

- 上下文随项目膨胀, 需要主动剪裁
- Plan 模式只读, 减少误动作 Token
- 可用 AI 网关做缓存与统一计费

OpenClaw / Pi

极小内核 · 低基线

4

个工具, 极小工具上下文

- 工具 schema 极少, 系统提示开销最低
- 复杂任务通过自我重写, 而非更多工具
- 成本结构跟着用户挑的模型走

GitHub Copilot

套餐封装 · 倍数放大

1 → 50×

模型倍数动态浮动

- Cloud Agent 整 Session 计 1 次, 性价比高
- 高级模型用倍数 (最高 50×) 控制需求
- Token 限额 (2026) 让长上下文成本可见

选型矩阵

什么时候用哪个？

场景	推荐	理由
我要在终端里高度可控地协同 LLM	OpenCode	开源 + BYOM, Plan 模式可审计
我想要一个轻量、可自我演进的私人 Agent	OpenClaw / Pi	极简内核 + 自我改写
我需要在 PR / Issue 上委派后台任务	Copilot Cloud	Session 计费, 与 GitHub 深度集成
我需要团队级许可、合规、统一计费	Copilot Enterprise	1000 Premium / 用户, IT 友好
我希望离线, 用本地模型跑 Agent	OpenCode + Local LLM	模型无关, 支持 Ollama 等

成本优化

把每个 Token 都花在刀口上



01

分层选模型

高频任务用便宜模型, 关键时刻才上
Opus / GPT-5



02

用好缓存

Anthropic 缓存命中价仅基础价 1/10, 长
系统提示尤其受益



03

Plan 优先

OpenCode Plan / 任务拆解先做规划, 再切
换到 Build



04

网关与配额

对 OpenCode / OpenClaw 引入 AI 网关, 做
集中配额与审计



05

委派 Cloud Agent

Copilot Cloud 整 Session 1 个 Premium, 长
任务最划算



06

限制 Agent 步数

每步都是 token, 给 Agent 设上限 + 终止
条件

 未来趋势

Token 经济将重塑开发者市场

01

请求计费 → Token 计费

GitHub 等平台逐步用 Token 限额取代固定 Request, 计费精度更接近真实算力。

02

本地模型回潮

OpenCode、Pi 等 BYOM 工具让本地推理回到选项, 数据合规与成本兼顾。

03

Agent of Agents

Build 调用 Plan、Plan 调用 Explore — 子代理复用让单次任务被切成多笔小账。

04

极简哲学复兴

OpenClaw / Pi 走红说明: 「四个工具 + 一颗强模型」可能比堆砌工具更可持续。

三句话总结

如果只能记住三件事

0

理解 **Token** 流向

无论用哪个平台, 先问: 「这个 token 是谁付钱、谁能看见?」 OpenCode 直通、Pi 直通, Copilot 经过套餐封装。

1

拥抱极简内核

OpenClaw 证明了 4 个工具就够。先用最小集合解决问题, 只在必要时再扩展, 通常更便宜也更稳。

2

为成本设计 **Agent**

限制循环步数、引入 Plan 模式、分层选模型、缓存系统提示 — 把 Token 放在工程化的层面去优化。

3

Thank You

「最好的 *Agent*, 不是工具最多, 而是 *Token* 用得最准。」

QUESTIONS

现场提问 / 茶歇继续

DEMO

三大平台现场对比演示

CONTACT

Kinfey Lo · Microsoft Cloud Advocate